- 3. JVM基础知识: 不积跬步, 无以至千里
 - 3.1 常见的编程语言类型
 - 1) 编程语言分类
 - 2) 高级语言分类
 - 3.2 关于跨平台
 - 3.3 关于运行时 (Runtime) 与虚拟机 (VM)
 - 3.4 关于内存管理和垃圾回收 (GC)
 - 参考材料

3. JVM基础知识: 不积跬步, 无以至千里

前面的章节我们介绍了JDK和JVM的关系以及环境准备等,本节我们来探讨一下JVM的基础知识,包括以下内容:

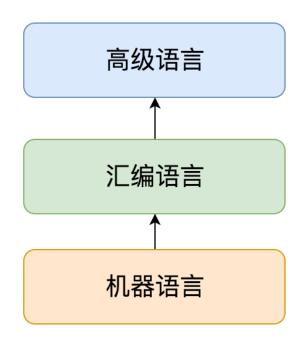
- 常见的编程语言类型
- 关于跨平台、运行时 (Runtime) 与虚拟机 (VM)
- 关于内存管理和垃圾回收 (GC)

3.1 常见的编程语言类型

我们都知道Java是一种基于虚拟机的静态类型编译语言。那么常见的语言可以怎么分类呢?

1) 编程语言分类

首先,我们可以把形形色色的编程从底向上划分为最基本的三大类:机器语言、汇编语言、高级语言。



按《计算机编程语言的发展与应用》一文里的定义: 计算机编程语言能够实现人与机器之间的交流和沟通, 而计算机编程语言主要包括汇编语言、机器语言以及高级语言, 具体内容如下:

- 机器语言:这种语言主要是利用二进制编码进行指令的发送,能够被计算机快速 地识别,其灵活性相对较高,且执行速度较为可观,机器语言与汇编语言之间的 相似性较高,但由于具有局限性,所以在使用上存在一定的约束性。
- 汇编语言:该语言主要是以缩写英文作为标符进行编写的,运用汇编语言进行编写的一般都是较为简练的小程序,其在执行方面较为便利,但汇编语言在程序方面较为冗长,所以具有较高的出错率。
- 高级语言:所谓的高级语言,其实是由多种编程语言结合之后的总称,其可以对多条指令进行整合,将其变为单条指令完成输送,其在操作细节指令以及中间过程等方面都得到了适当的简化,所以,整个程序更为简便,具有较强的操作性,而这种编码方式的简化,使得计算机编程对于相关工作人员的专业水平要求不断放宽。

简言之:机器语言是直接给机器执行的二进制指令,每种CPU平台都有对应的机器语言;

而汇编语言则相当于是给机器执行的指令,按照人可以理解的助记符表示,这样代码 就非常长,但是性能也很好;

高级语言则是为了方便人来理解,进而快速设计和实现程序代码,一般跟机器语言和汇编语言的指令已经完全没有关系了,代码编写完成后通过编译或解释,转换成汇编码或机器码,之后再传递给计算机去执行。

所以机器语言和汇编语言都是跟目标机器的CPU架构有直接联系,而高级语言一般就没有关系了,高级语言高级就高级在,一份代码往往是可以跨不同的目标机器的CPU架构的,不管是x86还是其他CPU,尽管不同CPU支持的指令集略有不同,但是都在编译或解释过程之后,变成实际平台的目标代码,进而代码的开发者很大程度上不需要关心目标平台的差异性。这一点非常重要,因为现代计算机软件系统的开发,往往开发者、测试者、部署运维者,并不是一拨人,特别是随着公有云的快速发展,我们甚至都不清楚自己的软件系统在容器下到底是什么物理架构。

2) 高级语言分类

如果按照有没有虚拟机来划分,高级编程语言可分为两类:

- 有虚拟机: Java, Lua, Ruby, 部分JavaScript的实现等等
- 无虚拟机: C, C++, C#, Golang, 以及大部分常见的编程语言

很奇怪的一件事儿,C#、Golang有GC(垃圾回收),也有运行时(Runtime),但是没有虚拟机(VM),为什么会这样设计呢?下文会详细讨论这个事情。

如果按照变量是不是有确定的类型,还是类型可以随意变化来划分,高级编程语言可以分为:

• 静态类型: Java, C, C++等等

• 动态类型: 所有脚本类型的语言

如果按照是编译执行,还是解释执行,可以分为:

- 编译执行: C, C++, Golang, Rust, C#, Java, Scala, Clojure, Kotlin, Swift...等等
- 解释执行: JavaScript的部分实现和NodeJS, Python, Perl, Ruby...等等

这里面,C#和Java都是编译后生成了一种中间类型的目标代码(类似汇编),但不是汇编或机器码,在C#中称为微软中间语言(MSIL),在Java里叫做 Java字节码(Java bytecode)。

虽然一般把JavaScript当做解释执行语言,但如今不少实现引擎都支持编译,比如 Google V8和Oracle Nashorn

此外,我们还可以按照语言特点分类:

- 面向过程: C, Basic, Pascal, Fortran等等
- 面向对象: C++, Java, Ruby, Smalltalk等等

• 函数式编程: LISP、Haskell、Erlang、OCaml、Clojure、F#等等

有的甚至可以划分为纯面向对象语言,例如Ruby,所有的东西都是对象(Java不是所有东西都是对象,比如基本类型 int 、 long 等等,就不是对象,但是它们的包装 类 Integer 、 Long 则是对象)。

还有既可以当做编译语言又可以当做脚本语言的,例如Groovy等语言。

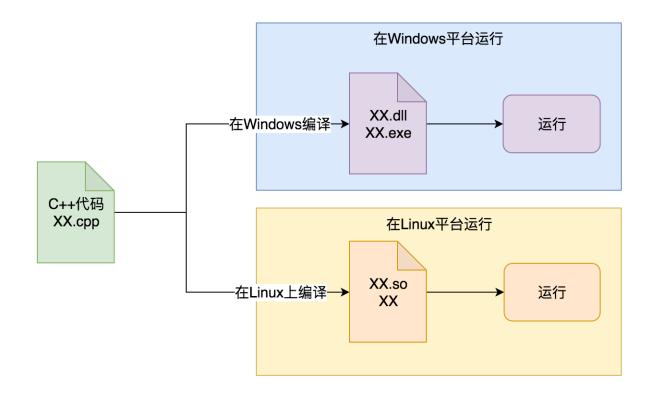
3.2 关于跨平台

现在我们聊聊跨平台,为什么要跨平台,因为我们希望所编写的代码和程序,在源代码级别或者编译后,可以运行在多种不同的系统平台上,而不需要为了各个平台的不同点而去实现两套代码。典型地,我们编写一个web程序,自然希望可以把它部署到Windows平台上,也可以部署到Linux平台上,甚至是MacOS系统上。

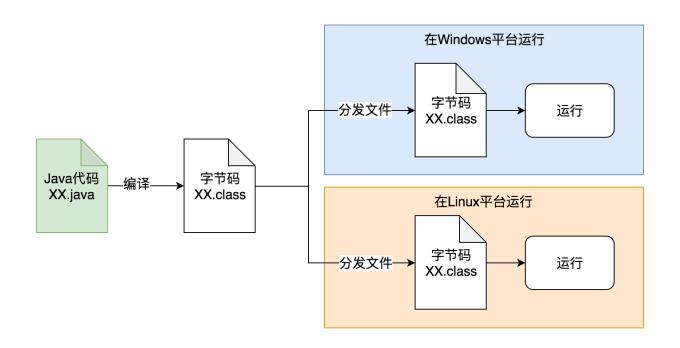
这就是跨平台的能力,极大地节省了开发和维护成本,赢得了商业市场上的一致好评。

这样来看,一般来说解释型语言都是跨平台的,同一份脚本代码,可以由不同平台上的解释器解释执行。但是对于编译型语言,存在两种级别的跨平台:源码跨平台和二进制跨平台。

1、典型的源码跨平台(C++):



2、典型的二进制跨平台(Java字节码):



可以看到, C++里我们需要把一份源码, 在不同平台上分别编译, 生成这个平台相关的二进制可执行文件, 然后才能在相应的平台上运行。 这样就需要在各个平台都有开发工具和编译器, 而且在各个平台所依赖的开发库都需要是一致或兼容的。 这一点在过去的年代里非常痛苦, 被戏称为"依赖地狱"。

C++的口号是"一次编写,到处(不同平台)编译",但实际情况上是一编译就报错,变成了"一次编写,到处调试,到处找依赖、改配置"。大家可以想象,你编译一份代码,发现缺了几十个依赖,到处找还找不到,或者找到了又跟本地已有的版本不兼容,这是一件怎样令人绝望的事情。

而Java语言通过虚拟机技术率先解决了这个难题。 源码只需要编译一次,然后把编译后的class文件或jar包,部署到不同平台,就可以直接通过安装在这些系统中的JVM上面执行。 同时可以把依赖库(jar文件)一起复制到目标机器,慢慢地又有了可以在各个平台都直接使用的Maven中央库(类似于linux里的yum或apt-get源,macos里的homebrew,现代的各种编程语言一般都有了这种包依赖管理机制: python的pip,dotnet的nuget,NodeJS的npm,golang的dep,rust的cargo等等)。这样就实现了让同一个应用程序在不同的平台上直接运行的能力。

总结一下跨平台:

- 脚本语言直接使用不同平台的解释器执行,称之为脚本跨平台,平台间的差异由不同平台上的解释器去解决。这样的话代码很通用,但是需要解释和翻译,效率较低。
- 编译型语言的代码跨平台,同一份代码,需要被不同平台的编译器编译成相应的 二进制文件,然后再去分发和执行,不同平台间的差异由编译器去解决。编译产 生的文件是直接针对平台的可执行指令,运行效率很高。但是在不同平台上编译

复杂软件,依赖配置可能会产生很多环境方面问题,导致开发和维护的成本较高。

编译型语言的二进制跨平台,同一份代码,先编译成一份通用的二进制文件,然后分发到不同平台,由虚拟机运行时来加载和执行,这样就会综合另外两种跨平台语言的优势,方便快捷地运行于各种平台,虽然运行效率可能比起本地编译类型语言要稍低一点。而这些优缺点也是Java虚拟机的优缺点。

现代商业应用最宝贵的是时间和人力,对大部分系统来说,机器相对来说就不是那么值钱了。

3.3 关于运行时 (Runtime) 与虚拟机 (VM)

我们前面提到了很多次 Java运行时 和 JVM虚拟机 ,简单的说JRE就是Java的运行时,包括虚拟机和相关的库等资源。

可以说运行时提供了程序运行的基本环境,JVM在启动时需要加载所有运行时的核心库等资源,然后再加载我们的应用程序字节码,才能让应用程序字节码运行在JVM这个容器里。

但也有一些语言是没有虚拟机的,编译打包时就把依赖的核心库和其他特性支持,一起静态打包或动态链接到程序中,比如Golang和Rust, C#等。

这样运行时就和程序指令组合在一起,成为了一个完整的应用程序,好处就是不需要虚拟机环境,坏处是编译后的二进制文件没法直接跨平台了。

3.4 关于内存管理和垃圾回收 (GC)

自从编程语言诞生以来,内存管理一直都是个非常重要的话题。因为内存资源总是有限而又宝贵的,只占用不释放,很快就会用完了。程序得不到可用内存就会崩溃(想想C++里动不动就出现的野指针)。

内存管理就是内存的生命周期管理,包括内存的申请、压缩、回收等操作。

Java的内存管理就是GC, JVM的GC模块不仅管理内存的回收, 也负责内存的分配和压缩整理。

我们从前面的内容可以知道,Java程序的指令都运行在JVM上,而且我们的程序代码并不需要去分配内存和释放内存(例如C/C++里需要使用的malloc/free),那么这些操作自然是由JVM帮我们搞定的。

JVM在我们创建Java对象的时候去分配新内存,并使用GC算法,根据对象的存活时间,在对象不使用之后,自动执行对象的内存回收操作。

对于Golang和Rust这些语言来说,其实也是存在垃圾回收的,但是它们没有虚拟机, 又是怎么实现的呢? 诀窍就在于运行时(Runtime),编译打包的时候,可以把内存使用分析的模块一起打包到应用程序中,在运行期间有专门的线程来分析内存使用情况,进而决定什么时候执行GC,把不再使用的内存回收掉。 这样就算是没有虚拟机,也可以实现GC。而Rust语言则更进一步,直接在语言规范层面限制了所有变量的生命周期,如果超出了一个明确的范围,就会不可用,这样在编译期就能直接知道每个对象在什么时候应该分配内存,什么时候应该销毁并回收内存,做到了很精确并且很安全的内存管理。

- C/C++完全相信而且惯着程序员,让大家自行管理内存,所以可以编写很自由的 代码,但一个不小心就会造成内存泄漏等问题导致程序崩溃。
- Java/Golang完全不相信程序员,但也惯着程序员。所有的内存生命周期都由 JVM/运行时统一管理。在绝大部分场景下,你可以非常自由的写代码,而且不 用关心内存到底是什么情况。内存使用有问题的时候,我们可以通过JVM来信息 相关的分析诊断和调整。这也是本课程的目标。
- Rust语言选择既不相信程序员,也不惯着程序员。让你在写代码的时候,必须清楚明白的用Rust的规则管理好你的变量,好让机器能明白高效地分析和管理内存。但是这样会导致代码不利于人的理解,写代码很不自由,学习成本也很高。

最后拿知乎上一个朋友 左之了 对这几种语言的评价来结尾:

首先,Rust是有点反人类,否则不会一直都不火。然后,Rust之所以反人类,是因为人类这玩意既愚蠢,又自大,破事还贼多。

你看C++就很相信人类,它要求人类自己把自己new出来的东西给delete掉。

C++: "这点小事我相信你可以的!"

人类: "没问题!包在我身上!"

然后呢,内存泄漏、double free、野指针满世界飘......

C++: "....."

Java选择不相信人类,但替人类把事办好。

Java: "别动, 让我来, 我有gc!"

人类: "你怎么做事这么慢呀? 你怎么还stop the world了呀? 你是不是不爱我了

呀?"

Java: "....."

Rust发现唯一的办法就是既不相信人类,也不惯着人类。

Rust: "按老子说的做,不做就不编译!"

人类: "你反人类!"

Rust: "滚!"

参考材料

- 1. 计算机编程语言的发展与应用: http://g.wanfangdata.com.cn/details/detail.do? _type=perio&id=dnbcjqywh201904012
- 2. JavaScript引擎: https://hllvm-group.iteye.com/group/topic/37596
- 3. GC 和虚拟机是两个一定要放在一起的概念

吗?: https://www.zhihu.com/question/45910460/answer/100056649

4. Rust 语言是否反人

类?: https://www.zhihu.com/question/328066906/answer/708085473